



进程间通信

陈海波/夏虞斌

上海交通大学并行与分布式系统研究所

https://ipads.se.sjtu.edu.cn

版权声明

- 本内容版权归上海交通大学并行与分布式系统研究所所有
- 使用者可以将全部或部分本内容免费用于非商业用途
- 使用者在使用全部或部分本内容时请注明来源:
 - 内容来自:上海交通大学并行与分布式系统研究所+材料名字
- 对于不遵守此声明或者其他违法使用本内容者,将依法保留追究权
- 本内容的发布采用 Creative Commons Attribution 4.0 License
 - 完整文本: https://creativecommons.org/licenses/by/4.0/legalcode

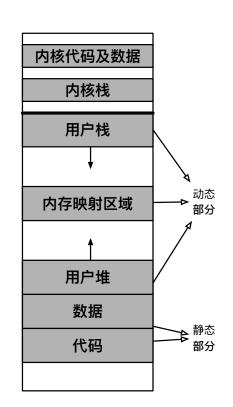
回顾: 进程

• 进程是计算机程序运行时的抽象

- 静态部分:程序运行需要的代码和数据
- 一 动态部分:程序运行期间的状态 (程序计数器、堆、栈……)

• 进程具有独立的虚拟地址空间

- 每个进程都具有"独占全部内存"的假象
- 内核中同样包含内核栈和内核代码、数据



应用程序的功能非常复杂

- ・ 独立进程: 一个进程就是一个应用
 - 不会去影响其他进程的执行,也不会被其他进程影响

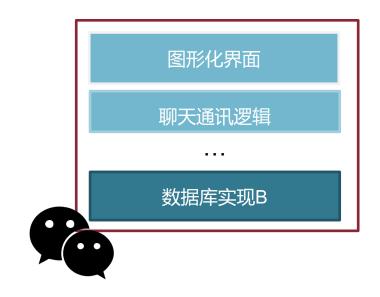
单个应用的功能非常复杂

| 附件管理 | 日历管理 | ・・・・ 通讯录 |
| 数据库服务 | 系统资源监 控

独立进程的问题1: 大量重复实现

- 聊天软件和邮件软件都依赖数据库
- · 各自实现一份在自己的进程中





独立进程的问题2: 低效实现

- 聊天软件的数据库实现经过精心的优化
- 邮件软件团队的开发重心在其他组件上
 - 借用低效的某数据库开源实现



独立进程的问题3: 没有信息共享

• 邮件和聊天软件都需要监控系统资源信息

- ・没有信息共享
 - 即使邮件软件已经完成了计算,聊天软件也要重新计算一遍

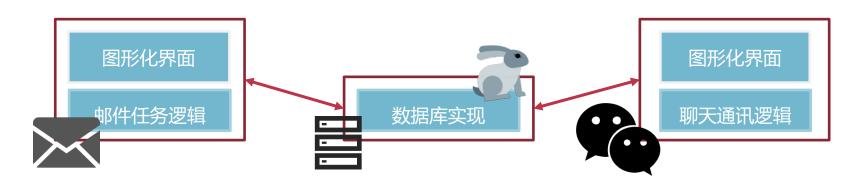
如果进程可以协作

• 协作进程

- 和独立进程相反,可以影响其他进程执行或者被影响

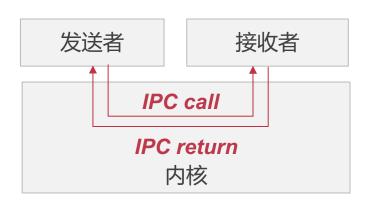
好处

- 模块化:数据库单独在一个进程中,可以被复用
- 加速计算: 不同进程专注于特定的计算任务, 性能更好
- 信息共享: 直接共享已经计算好的数据,避免重复计算



进程间通信

- 进程协作的达成依赖于进程间通信
- · 进程间通信: 两个(或多个)不同的进程,通过内核或其他 共享资源进行通信,来传递控制信息或数据
 - 交互的双方: 发送者/接收者、客户端/服务端、调用者/被调用者
 - 通信的内容一般叫做"消息"

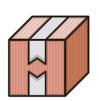


新冠疫情下快递员送货问题

· 快递员不能送快递到家门口







• 小明的手机被没收了

快递员





• 快递员和小明怎么联络呢?



发送者 接收者

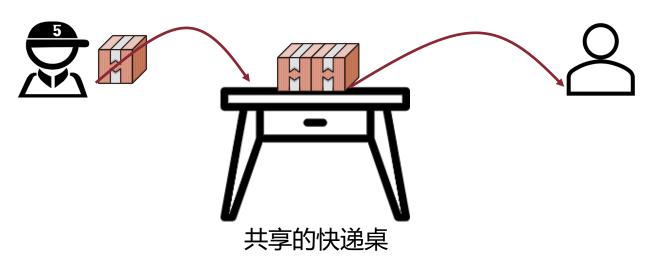


消息

快递员问题→进程间通信问题

共享内存: 共享一块区域

- 小区门口的桌子上允许临时放置快递
- · 快递员在桌上放置快递,小明从桌上取快递



- 系统内核为两个进程映射共同的内存区域
 - 快递员和小明的快递桌

- ・ 挑战: 做好同步
 - 发送者不能覆盖掉未读取的数据 (新快递把旧的快递挤下桌)
 - 接收者不能读取没有准备好的数据 (小明拿错了快递)

· 基础实现: 共享区域(快递桌)

```
#define BUFFER_SIZE 10

typedef struct {
    ...
} item;

item buffer[BUFFER_SIZE];

int in = 0;
int out = 0;
```

基础实现: 发送者(快递员) 当没有空间时,发送者盲目等待 while (new package) { (快递员等待桌子有空闲空间) /* Produce an item */ while (((in = (in + 1) % BUFFER SIZE) == out) /* do nothing -- no free buffers */ buffer[in] = item; in = (in + 1) % BUFFER SIZE;发送者放置消息 (快递员将快递放在桌上空闲空间)

当没有新消息时,接收者盲目等待 ・ 基础实现: 接收者(小明) (小明盲目查看桌上状态和等待) while (wait_package) { while (in == out) ; // do nothing -- nothing to consume // remove an item from the buffer item = buffer[out]; out = (out + 1) % BUFFER SIZE; return item; 接收者获取消息 (小明拿到最先到达的一个快递)

共享内存的问题

• 轮询导致资源浪费

- 小明时不时就得下楼检查一下快递桌子
- 快递员需要等待桌子有空闲空间
- 一天大部分时间都花在了上下楼和检查快递上了

· 固定一个检查时间,时延长

- 小明每天晚上检查一下有没有新的快递过来
- 早上到达的快递要晚上才能拿到

消息传递:拿到了手机的小明

- 小明终于说服了妈妈,拿到了手机
- ・ 消息系统 (手机)
 - 通过中间层(如内核)保证通信时延,仍然可以利用共享内存传递数据



好处: 1) 低时延(消息立即转发)

2)不浪费计算资源

消息传递

- ・ 基本操作:
 - 发送消息Send(message)
 - 接收消息Recv(message)

- · 如果两个进程P和Q希望通过消息传递进行通信,需要:
 - 建立一个通信连接
 - 通过Send/Recv接口进行消息传递

直接通信: 快递员直接拨打小明手机

· 快递员和小明交换手机号来建立连接

- 手机号唯一地标识了快递员和小明
- Send(P, message): 给P进程发送一个消息
- Recv(Q, message): 从Q进程接收一个消息

• 直接通信下的连接

- 连接的建立是自动的(通过标识,即手机号)
- 一个连接唯一地对应一对进程
- 一对进程之间也只会存在一个连接
- 连接可以是单向的,但是在大部分情况下是双向的

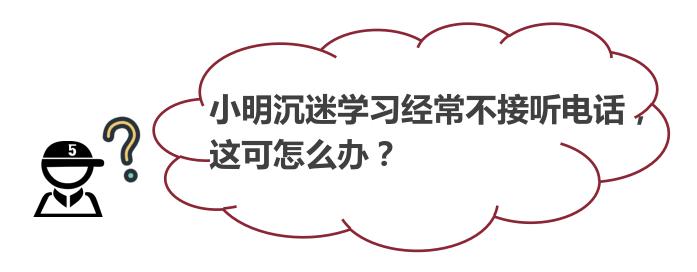
直接通信: 快递员直接拨打小明手机

• 发送者(快递员)

```
接收者(小明)
while (new package) {
  /* Produce an item */
                                         while (wait package) {
  while (((in = (in + 1) % BUFFER SIZE)
                                               Recv(Expressman, Msg);
         == out)
                                               item = buffer[out];
       ; /* nothing, no free buffers */
                                              out = (out + 1) % BUFFER SIZE;
   buffer[in] = item;
                                               return item;
   in = (in + 1) \% BUFFER SIZE;
    Send(XiaoMing, "Package");
```

小明的Recv会阻塞,直到快递员的Send发送消息过来,避免盲目等待

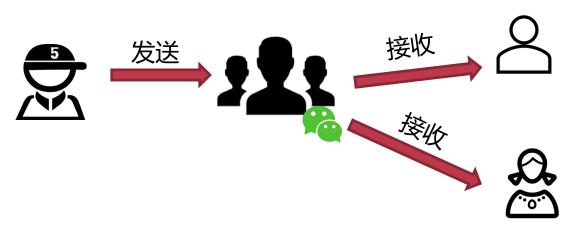
快递员有好多苦恼 (1)



- · 快递员执行Send的时候,小明还没有Recv
- · 快递员知道小明妈妈经常在家,希望建立一个聊天群,在群里发布快递信息
- · 小明不接听时可以拜托妈妈下来拿快递

间接通信: 用聊天群发布快递信息

- 消息的发送和接收需要经过一个"信箱"
 - 聊天群 (所有在群内的人都可以接收消息)
 - 每个"信箱"有自己唯一的标识符(这里的群号)
 - 发送者往"信箱"发送消息,接收者从"信箱"读取消息



间接通信

· 间接通信下的连接

- 进程间连接的建立发生在共享一个信箱时
- 每对进程可以有多个连接 (共享多个信箱)
- 连接同样可以是单向的或双向的

• 间接进程间通信的操作

- 创建一个新的信箱
- 通过信箱发送和接收消息
- 销毁一个信箱

原语

- Send(A, message): 给信箱A发送一个消息
- Recv(A, message): 从信箱A接收一个消息

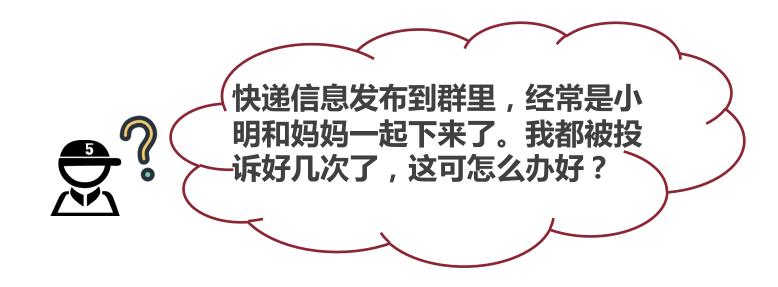
间接通信: 用聊天群发布快递信息

• 发送者(快递员)

```
接收者(小明)
while (new package) {
  /* Produce an item */
                                           Recv(Group, Msg);
  while (((in = (in + 1) \%))
  BUFFER SIZE)
                                          接收者(小明妈妈)
         == out)
                                           Recv(Group, Msg);
       ; /* nothing, no free buffers */
   buffer[in] = item;
   in = (in + 1) % BUFFER_SIZE;
    Send(Group, "Package");
```

小明或者妈妈任何一个人只要上聊天群,就能看到快递信息

快递员有好多苦恼 (2)



• 怎么解决"信箱"共享带来的多接收者的问题呢?

信箱共享的挑战

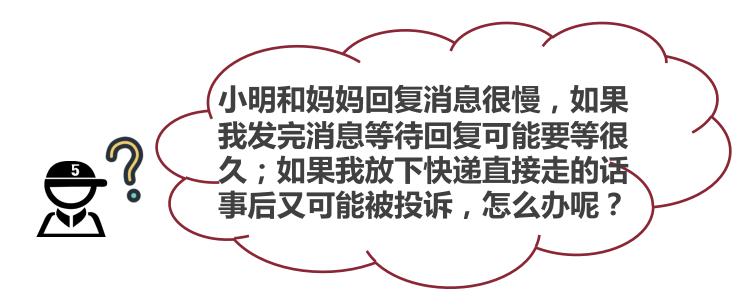
· 信箱的共享

- 进程P₁、P₂和P₃共享一个信箱A
- P₁负责发送消息, P₂、P₃负责接收消息
- 当一个消息发出的时候,谁会接收到最新的消息呢?

· 可能的解决方案

- 让一个连接(信箱)只能被最多两个进程共享,避免该问题
- 同一时间,只允许最多一个进程在执行接收信息的操作
- 让消息系统任意选择一个接收者 (需要通知发送者最终的接收者)

快递员有好多苦恼 (3)



· 快递员想要弄清楚自己是等待消息被确认呢(阻塞),还是 发送完消息就赶去送下一个快递呢(非阻塞)?

消息传递的同步与异步

- 消息的传递可以是阻塞的,也可以是非阻塞的
- · 阻塞通常被认为是同步通信
 - 阻塞的发送/接收: 发送者/接收者一直处于阻塞状态,直到消息发出/到来
 - 同步通信通常有着更好的时延和易用的编程模型 (不会被投诉)
- · 非阻塞通常被认为是异步通信
 - 发送者/接收者不等待操作结果,直接返回
 - 异步通信的带宽一般更高 (快递员可以送更多的快递)

超时机制

· 为了好评, 快递员选择:





- 尽可能等待(同步的通信)
- 但是一旦超过一个值 (如15分钟),就先带走快递,等下再配送

• 超时机制的引入

- Send(A, message, Time-out)
 - 超过Time-out限定的时间就返回错误信息
- 两个特殊的超时选项: ① 一直等待(阻塞);②不等待(非阻塞)
- 避免由通信造成的拒接服务攻击等

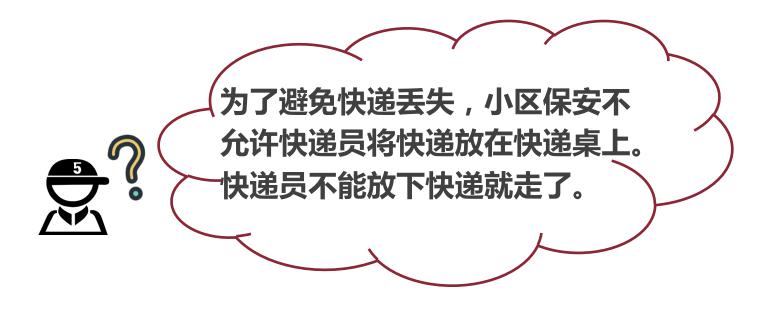
同步通信和超时机制

• 发送者(快递员)

```
接收者(小明)
while (new package) {
  /* Produce an item */
                                              Recv(Group, Msg, Time-out);
  while (((in = (in + 1) % BUFFER SIZE)
         == out)
       ; /* nothing, no free buffers */
                                             接收者(小明妈妈)
  buffer[in] = item;
                                            Recv(Group, Msg, Time-out);
  in = (in + 1) % BUFFER SIZE;
  if (Send(Group, "Package", "15min")
  == error)
      goto retry;
```

快递员决定等待最多15分钟,一旦超时就放弃这一次派送

快递员有好多苦恼 (4)



· 有手机后,快递桌的作用有什么变化吗?

通信连接的缓冲: 快递桌的作用

- 缓冲: 通信连接可以选择保留住还没有处理的消息
- 常见的三种设计
 - **零容量:** 通信连接本身不缓冲消息,发送者只能阻塞等待接收者接收消息 (保安不提供快递桌)
 - **有限容量:** 连接可以缓冲最多N个消息,当缓冲区满之后发送者只能阻塞等待(快递只能放在桌上,但是空间有限)
 - 无限容量: 连接可以缓冲系统资源允许下的任意数量的消息,发送者几乎不需要等待(快递可以放在门口任何位置)

UNIX IPC

UNIX经典IPC

Unix 管道

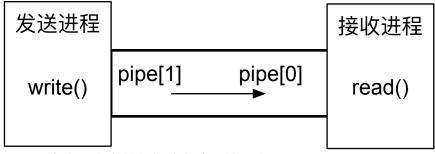
- · 管道是Unix等宏内核系统中非常重要的进程间通信机制
- · 管道(Pipe): 两个进程间的一根通信通道
 - 一端向里投递,另一端接收
 - 管道是间接消息传递方式,通过共享一个管道来建立连接
- ・ 例子: 我们常见的命令 Is | grep

```
→ os-textbook git:(master) ls | grep ipc ipc.tex
```

Unix 管道

・ 管道的特点:

- 单向通信, 当缓冲区满时阻塞
- 一个管道有且只能有两个端口:一个负责输入(发送数据),一个负责输出(接收数据)
- 数据不带类型,即字节流
- 基于Unix的文件描述符使用



Unix 管道

· Xv6为例: 管道数据结构

```
连接缓冲区域,定长
struct pipe {
struct spinlock lock;
char data[PIPESIZE];
uint nread;
uint nwrite;
int readopen;
int writeopen;
};

struct pipe {
struct spinlock lock;
char data[PIPESIZE];
uint nread;
// number of bytes read
// number of bytes written
// read fd is still open
// write fd is still open
};
```

Unix 管道

・ Xv6为例: 管道写操作

int

```
pipewrite(struct pipe *p, char *addr, int n)
                            int i;
                            acquire(&p->lock);
    检查缓冲区域是否满
                            for(i = 0; i < n; i++) {
                              while(p->nwrite == p->nread + PIPESIZE)
                                 pipewrite-full
      如果读者不存在
                                if(p->readopen == 0 | proc->killed)
                                 release (&p->lock);
      那么返回错误信息
                                 return −1;
                                wakeup(&p->nread);
尝试唤醒读者去读消息
                                sleep(&p->nwrite, &p->lock);
                                                             pipewrite-sleep
        并将自己阻塞住
                              p->data[p->nwrite++ % PIPESIZE]
                                                          = addr[i]
                                              // pipewrite-wakeup1
                            wakeup(&p->nread);
                            release(&p->lock);
  往缓冲区域上放置消息
                            return n;
```

Unix 管道

· Xv6为例: 管道读操作

```
int
                           piperead(struct pipe *p, char *addr, int n)
                             int i;
                             acquire(&p->lock);
                             while (p->nread == p->nwrite && p->writeopen) {
  检查是否有消息
                              → pipe-empty
                               if(proc->killed){
                                 release(&p->lock);
                                 return −1;
阻塞等待消息到来
                               sleep(&p->nread, &p->lock); // piperead-sleep
                             for(i = 0; i < n; i++){ // piperead-copy</pre>
                               if(p->nread == p->nwrite)
         读取消息
                                break;
                               addr[i] = p->data[p->nread++ % PIPESIZE];
                             wakeup(&p->nwrite); // piperead-wakeup
                             release(&p->lock);
                             return i;
```

扩展: Sleep/Wakeup通信机制

- Xv6管道实现中依赖于sleep和wakeup两个接口
- Xv6中的sleep和wakeup是经典的进程间等待(wait)和通知 (notify)的机制
- 信道(Channel)是等待和通知的媒介
- 一个进程可以通过sleep接口将自己等待在一个信道上
- 另外一个进程可以通过wakeup将等待在某个信道上的进程唤醒

扩展: Sleep/Wakeup通信机制

- · Xv6中的sleep实现
 - 进程结构体(curproc)中存在一项chan的一项

把当前的进程状态设置为阻塞,然后调度到其他进程

扩展: Sleep/Wakeup通信机制

· Xv6中的wakup实现

查找所有的目前等待在chan上的进程,并唤醒他们(设置为可执行)

```
void wakeup(void *chan):
    //critical_section_begin

foreach p in ptable[]: //ptable 中存放所有进程结构
    if p->chan == chan and p->state == SLEEPING:
        p->state = RUNNABLE

//critical_section_end
```

遍历所有的进程结构,如果chan和参数一致,设为可运行

管道的优点与问题

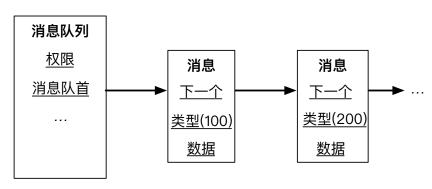
- · 优点:设计和实现简单
 - 针对简单通信场景十分有效

• 问题:

- 缺少消息的类型,接收者需要对消息内容进行解析
- 缓冲区大小预先分配且固定
- 只能支持单向通信
- 只能支持最多两个进程间通信

消息队列: 带类型的消息传递

- 消息队列: 以链表的方式组织消息
 - 任何有权限的进程都可以访问队列,写入或者读取
 - 支持异步通信(非阻塞)
- ・ 消息的格式: 类型 + 数据
 - 类型:由一个整型表示,具体的意义由用户决定
- · 消息队列是间接消息传递方式
 - 通过共享一个队列来建立连接



消息队列: 带类型的消息传递

- 消息队列的组织
 - 基本遵循FIFO (First-In-First-Out)先进先出原则
 - 消息队列的写入:增加在队列尾部
 - 消息队列的读取:默认从队首获取消息
- 允许按照类型查询: Recv(A, type, message)
 - 类型为0时返回第一个消息 (FIFO)
 - 类型有值时按照类型查询消息
 - 如type为正数,则返回第一个类型为type的消息

消息队列 VS 管道

缓存区设计:

- 消息队列:链表的组织方式,动态分配资源,可以设置十分大的上限
- 管道: 固定的缓冲区间,分配过大资源容易造成浪费

・ 消息格式:

- 消息队列: 带类型的数据
- 管道: 数据 (字节流)

· 连接上的通信进程:

- 消息队列: 可以有多个发送者和接收者
- 管道: 两个端口, 最多对应两个进程

· 消息的管理:

- 消息队列: FIFO + 基于类型的查询
- 管道: FIFO

消息队列更加灵活易用, 但是实现也更加复杂

Lightweight Remote Procedure Call (LRPC)

轻量级远程方法调用 (LRPC)

Unix进程间通信机制通常十分重量级

• 现有机制

一管道,信号,域套接字,共享内存,信号量,消息队列,等等

· 传统宏内核系统中的通信机制通常会结合:

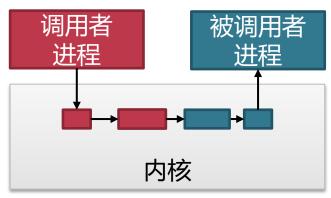
- 通知: 告诉目标进程事件的发生
- 调度: 修改进程的运行状态以及系统的调度队列
- 数据的传输: 传输一个消息的数据过去

• 缺少一个轻量的远程调用机制

- 客户端进程切换到服务端进程,执行特定的函数 (Handler)
- 参数的传递和结果的返回

轻量级远程调用 (LRPC)

- Lightweight Remote Procedure Call (LRPC)
- · 解决两个主要问题
 - 控制流转换: 调用者进程快速通知被调用者进程
 - 数据传输: 将栈和寄存器参数传递给被调用者进程



控制流转换: 调度导致不确定时延

- 控制流转换需要下陷到内核
- 内核系统为了保证公平等,会在内核中根据情况进行调度
 - 调用者和被调用者之间可能会执行多个不相关进程

用户期望的控制流转换 调用者 进程 内核 进程 被调用者 进程 不相关进程

上海交诵大学并行与分布式系统研究所(IPADS@SJTU

49

迁移线程: 将调用者运行在被调用上下文

- · 为什么需要做控制流转换?
 - 使用被调用者的代码和数据
 - 使用被调用者的权限 (如访问某些系统资源)
- 只切换地址空间、权限表等状态,不做调度和真正的线程 切换
 调用者进程获得了被调用者的上下文

週用者 进程 内核 进程 进程

数据传输: 万恶之源的数据拷贝

- · 大部分Unix类系统,经过内核的传输有(至少)两次拷贝
 - 调用者→内核→被调用者
- 数据拷贝:
 - 慢: 拷贝本身的性能就不快 (内存指令)
 - 不可扩展: 数据量增大10x, 时延增大10x



共享参数栈和寄存器

- · 参数栈 (Argument stack, 简称A-stack)
 - 系统内核为每一对LRPC连接预先分配好一个A-stack
 - A-stack被同时映射在调用者进程和被调用者进程地址空间
 - 调用者进程只需要将参数准备到A-stack即可
 - 不需要内核额外拷贝

・共享寄存器

- 普通的上下文切换: 保存当前寄存器状态 → 恢复切换到的进程寄存器 状态
- LRPC迁移进程: 直接使用当前的通用寄存器
 - 类似函数调用中用寄存器传递参数

轻量远程调用: 通信连接建立

- 被调用者进程通过内核注册一个服务描述符
 - 对应被调用者进程内部的一个处理函数(Handler)
- · 内核为服务描述符预先分配好参数栈
- · 内核为服务描述符分配好调用记录 (Linkage record)
 - 调用记录被用作从被调用者进程处返回
- 内核将参数栈交给客户端进程,作为一个绑定成功的标志
 - 在通信过程中,通过检查A-stack来判断调用者是否正确发起通信

轻量远程调用: 基本用户接口

• 服务端进程

① 注册服务描述符

```
service_descriptor =
  register_service(handler_func, &A-
  stack, &E-stack);
```

```
void handler_func (A-stack, arg0,...
arg7) {
u64 ret;
//从寄存器和A-stack中获取参数
// 使用E-stack(运行栈)来处理
...
//返回结果
ipc_return (ret);
}
```

客户端进程

② 连接服务并调用

```
A-stack =
service_connect(service_name);
/* 准备数据到A-stack */
...
/*arg0—7 为寄存器数据*/
ipc_call(A-stack, arg0, .. arg7);
```

③ 用A-stack和寄存器获取参数,用运行栈来执行逻辑

轻量远程调用: 一次调用过程

- 1. 内核验证绑定对象的正确性,并找到正确的服务描述符
- 2. 内核验证参数栈和连接记录
- 3. 检查是否有并发调用 (可能导致A-stack等异常)
- 4. 将调用者的返回地址和栈指针放到连接记录中
- 5. 将连接记录放到线程控制结构体中的栈上 (支持嵌套LRPC调用)
- 6. 找到被调用者进程的运行栈(执行代码所使用的栈)
- 7. 将当前线程的栈指针设置为被调用者进程的运行栈地址
- 8. 将地址空间切换到被调用者进程中
- 9. 执行被调用者地址空间中的处理函数

轻量远程调用: 通信调用实现

内核

```
ipc call(A-stack, arg0, .. arg7):
  verify binding(A-stack); //验证A-stack正确性
  service descriptor = get desc from A(A-stack);
  /*其他安全检查: 是否存在并发调用?*/
  save ctx to linkage record(); //保存调用信息到连接记录上
  save linkage record();
  /* 切换运行状态 */
  switch PT(); //修改页表
  switch cap table(); //修改权限表
  switch sp(); //修改栈地址
  //返回到用户态(服务端进程),不修改参数寄存器
  ctx restore with args (ret);
```

轻量远程调用: 讨论

· 为什么需要将栈分成参数栈和运行栈?

· LRPC中控制流转换的主要要开销来自哪?

· 不考虑多线程的情况下, 共享参数栈安全吗?

ChCore IPC

CHCORE进程间通信

ChCore进程间通信

- · 通信进程直接切换
 - 启发自LRPC和L4直接切换技术
- ・同步的通信
- · 通过共享内存传输大数据
- · 基于Capability的权限控制
 - 类似Unix文件描述符的权限机制, Capability表示一个线程/进程对于系统资源的具体权限

建立通信连接

- 1. 服务端进程在内核中注册服务
- 2. 客户端进程向内核申请连接目标服务端进程的服务
 - 可选: 设置共享内存
- 3. 内核将客户端请求请求转发给服务端
- 4. 服务端告诉内核同意连接 (或拒绝)
 - 可选: 设置共享内存
- 5. 内核建立连接,并把连接的Capability返回给客户端 (或返回 拒绝)

通信过程 (发起通信)

- 1. 客户端进程通过连接的Capability发起进程间通信请求
- 2. 内核检查权限, 若通过则继续步骤3, 否则返回错误
- 3. 内核直接切换到服务端进程执行 (不经过调度器)
 - 将通信请求的参数设置给服务端进程的寄存器中
- 4. 服务端处理完毕后,通过与步骤3相反的过程将返回值传 回客户端

实现: 用户态通信调用

```
void ipc_dispatcher(ipc_msg_t *ipc_msg) {
   u64 ret:
   char* data = ipc_get_msg_data(ipc_msg);
   // handling ipc accordingly...
   ipc_return(ret);
void server() {
   // ...
   ipc_register_server(ipc_dispatcher);
   // ...
```

实现: 通信系统调用

IPC_call

获取内核的连接对象,检查cap 权限

```
struct ipc_connection *conn = NULL;
  u64 arg;
  int r;
  conn = obj_get(current_thread->process, conn_cap, TYPE_CONNECTION);
                                            在传递之前需要将ipc_msg在客
  /* Message Processing*/
  // do some thing...
                                            户进程的虚拟地址转换到服务进
                                            程中的虚拟地址
  arg = get_srv_vmaddr(ipc_msg);
  thread_migrate_to_server(conn, arg);
  BUG("This function should never\n");
  return 0;
                            将控制流移交给服务进程
```

实现: 通信系统调用

IPC_return

```
void sys_ipc_return(u64 ret) {
    struct ipc_connection *conn = current_thread->active_conn;

thread_migrate_to_client(conn, ret);

BUG("This function should never\n");
}
```

将控制流移交给客户进程

下次课内容

· 多处理器与多核